

CARE 2026 Myocardium 的选择性表示检索方法蓝图

结论先行

CARE 2026 Myocardium 不是一个普通的“三通道输入分割”题目，因为它同时存在三类结构化困难：其一，MyoPS 训练集的模态缺失不是随机缺失，而是和中心、标签可用性以及病理类型纠缠在一起；其二，验证与测试都是完整三模态，而训练中大量样本只有 LGE 或 LGE+C0，因此存在显著的 missingness shift；其三，CineMyoPS 的原始数据是 4D cine，而目前很多 wrapper 只取单帧，天然丢掉了 CineMyoPS 论文最核心的 motion、anatomy 与 time-series aggregation 机制。CARE 官方页面明确写出，MyoPS 训练数据按中心分布为 81 例仅 LGE、80 例 LGE+T2+bSSFP、以及 24 例 LGE+bSSFP；验证集 MyoPS 的 15 例全部是完整三模态；CineMyoPS 训练集为 40 + 24 例 cine，验证集为 15 例 cine；排行榜分别对应 myops_scar、myops_edema 与 myocardium_cinemyops 三个指标，且官方原始标签值是 scar 2221、edema 1220、LV 500、myocardium 200、RV 600。这些设定决定了“把缺失模态补零后当多通道输入”既不尊重数据机制，也很容易把中心 shortcut 学进模型。[1]

我的最终判断是：值得把 R2/BR2 作为正式故事的统一原则，但不值得把原论文中的线性 source-specific learner 与原始 SIP 直接照搬成分割模型。更准确地说，应该把 R2/BR2 改写成一个分割原生的、availability-aware 的 shared/private representation retrieval 框架：把“representer dictionary”落在多尺度特征块与小型 expert block 上，把“source-specific sparse learner”落在病理头与样本条件化路由上，把 BR2 的观测指示器改成模态可用性掩码与 T2 条件监督，把 SIP 改成可微的 soft integrativeness regularizer，从而得到一个能在 7-10 天内真正落地的正式方法。对于 Cine，推荐同原则、分故事：理念上统一为“从当前可用的模态或时相中检索可靠表示”，但论文叙事与工程实现上仍分成 MyoPS 主线和 Cine 主线，两者共享 retrieval 原则，不强行做一个重型总模型。[2]

一句话问题定义可以写成：CARE 的核心难点不是多模态融合本身，而是“缺模态、中心偏移、标签条件可用性、以及时序信息缺失”同时发生时，如何只从当前可信的证据里检索对目标最有用的表示。一句话方法主张可以写成：我们提出 Selective Representation Retrieval for Partially Observed Cardiac MR，在每个尺度上从共享与模态私有表示字典中稀疏检索可靠特征，并通过病理特异解码、T2 条件监督与解剖先验，把缺模态和多中心异质性转化成可控的条件计算问题。这个表述既保留了 R2/BR2 的精神，又不会越界声称原理论已直接证明 dense CMR segmentation 场景。[3]

四篇核心论文的可用信息与真正可借之处

MyoPS-Net 的真正价值，不在于“给缺失模态补零”这个表面接口，而在于它明确把问题拆成三层：第一层是对不同序列进行灵活的 cross-modal feature fusion，使网络能接受不同数量、不同组合的 CMR 序列；第二层是针对 scar 与 edema 设立 pathology-specific 输出分支，因为二者的主要证据来源与形态统计明显不同；第三层是把 myocardium consistency / localization 与 pathology inclusiveness 显式写进训练目标，利用病灶通常位于心肌区域内、scar 与 edema 在病理学上又存在包含与邻近关系的假设来约束预测。论文摘要明确写到，该方法能处理 “different numbers of CMR images and complex combinations of modalities”，并使用 “output branches targeting specific pathologies” “myocardium consistency and localize the pathologies” “inclusiveness loss to utilize relations between myocardial scars and edema”；官方代码仓库给出 MIT 许可证与训练/预测入口，但未看到公开 release 权重。对 CARE 而言，真正该借的是“灵活融合 + pathology-specific decoder + anatomy prior”，不是把缺模态通道直接 zero-filled 后当论文忠实复现，因为 CARE 的缺失模式与中心绑定，补零会非常容易让“无 T2”变成“edema 不该出现”的伪规则。[4]

U-MyoPS 的方法故事则完全不同。它把 LGE 选为 common reference，先做 TPS 风格的跨序列配准，再在共同空间里融合特征、提取 myocardium、最后用 prior-aware 子网络做 pathology segmentation。官方摘要与代码页都强调，这是一个 registration-before-fusion 的框架：先 “align multi-sequence CMR images into a common space”，再 “aggregates multi-sequence features into a common space to extract anatomical structures”，并利用 extracted myocardium 去 highlight informative regions；官方仓库显示实现包括 joint registration and myocardium segmentation，以及基于 nnUNet 的 prior-aware pathology segmentation，许可证为 Apache-2.0。这个故事在“全序列、未配准、标签齐全”时非常完整，但不适合做你们当前主线：一方面 CARE 训练里大批样本根本没有 T2/C0，另一方面你们自己的当前仓库也明确把 MyoPS-Net 与 U-MyoPS 视作 “negative evidence and mechanism sources”，并指出 edema 的关键失败区在 complete-modality 的 CenterC，说明现阶段最大瓶颈更像缺模态与中心行为，而不是先验假定“所有样本都应先完成配准再融合”。因此 U-MyoPS 更适合作为可插拔 alignment ablation 的思想来源，而不是正式主线。[5]

CineMyoPS 的关键不是“用 cine 做 scar/edema”，而是如何把 anatomy、motion、texture 三类信息在 ED 参考空间中联合起来。论文网页清楚给出三个模块：myocardial motion estimation、anatomy segmentation、MyoPS segmentation；以 ED frame 作为 common reference image；对每个时相估计 DDF，把 anatomy 特征和 texture 特征 warp 到 reference space，再在整个 cardiac cycle 上做 time-series aggregation；同时使用 consistency loss，在只有 ED anatomy 标注的条件下，通过 motion-induced consistency 让 anatomy 模块学习全时序。作者还在 ablation 中显示，time-series aggregation 与 consistency loss 都带来收益，并指出大约使用 4/6 的帧数是信息量与计算量之间的平衡点。由此可见，单帧 cine wrapper 并没有使用论文最核心的 ED reference、motion field、warped features 与 time aggregation 思想，所以不能把“单帧 compact wrapper”写成 CineMyoPS 的实现故事。[6]

R2/BR2 的价值在于它提供了一个非常清楚的抽象：用 **representer dictionary** 去表示复杂异质性，再让每个 source 通过**稀疏 learner** 去检索最适合自己的表示；在 BR2 中，又引入 modality-specific dictionary 与 observation indicator，避免对 blockwise missingness 做不可检验的插补。论文明确说，R2 使用 “dictionary of representation learning modules” 与 “data source-specific sparsity-induced learners”；integrativeness 是 “the number of data sources retrieving the specific representer”；BR2 用 modality-specific dictionaries，并通过 $I_m^{(s)}$ 指示缺失模态对预测不起作用；此外，作者也明确承认单纯的 modality-specific dictionary 只刻画 main effects，如要恢复跨模态 interaction，可以引入 interaction dictionaries，或者使用 sparse-input neural nets。与此同时，这篇工作当前的理论与实验主要还是面向 regression / classification / tabular-like heterogeneous integration，论文自己提到理论分析与数值实验仍基于 modality-specific dictionaries 与线性 learners，因此**不能直接宣称它已经覆盖 dense segmentation 的空间特征选择问题**。但它非常适合作为 CARE 主线的 “原则层”，而不是 “现成结构层”。[7]

首选正式架构

我建议首选正式架构命名为 **Selective Representation Retrieval for Partially Observed Multi-sequence CMR**，简称 **SRR-MyoPS**。它的文字版架构图可以这样写：输入端有三个 modality-specific stems，分别处理 LGE、C0 与 T2；每个 stem 之后进入一个四尺度编码器，编码器的每个尺度都不直接进入传统 skip concat，而是先送入一个表示字典层。这个字典层由三部分组成：共享表示字典 $\mathcal{D}_{sh}^\ell$ 、模态私有字典 $\mathcal{D}_{lge}^\ell, \mathcal{D}_{c0}^\ell, \mathcal{D}_{t2}^\ell$ ，以及一个可选的小型 interaction dictionary $\mathcal{D}_{mix}^\ell$ 。对每个尺度 ℓ ，router 不仅看 availability mask $m \in \{0, 1\}^3$ ，还看由当前样本局部特征池化得到的 routing query；它输出三个病理目标各自的 sparse gate：anatomy gate、scar gate 与 edema gate。随后，三个 decoder 分别执行：anatomy decoder 为 myocardium/LV/RV 或 myocardium union prior 生成软解剖图；scar decoder 以 LGE 主导，从共享 + LGE 私有 + 少量 C0 辅助表示中检索；edema decoder 以 T2 主导，从共享 + T2 私有 + 少量 C0/LGE 辅助表示中检索。所有 pathology 输出再经过 anatomy prior gate 做空间抑制。若 complete tri-modal 子集的定性诊断明确显示跨序列错位主导误差，才在 LGE-reference feature level 接入一个 tri-modal alignment expert；否则正式版中先不启用。这个设计直接对应 CARE 的三类指标：scar 由 LGE 主分支负责，edema 由 T2 条件分支负责，cine 则单独采用 temporal retrieval 的轻量故事。[8]

这里最关键的设计问题，是把 representer 放在哪一层。我不建议把 representer 定义成完整 encoder，也不建议在 7-10 天里做 token-level transformer dictionary。最合适的落点是**多尺度 feature block 级别的小 expert bank**，例如每个尺度上放 $K_{sh} = 4$ 个共享 expert 与每个模态 $K_m = 2$ 个私有 expert，每个 expert 本质上是一个轻量残差卷积块或 1-2 层深度可分离卷积块。这样既保留 R2/BR2 的 “可检索表示词典” 味道，又能稳定嵌入 nnU-Net / MONAI 风格 3D U-Net。对 dense prediction 而言，这是比 “全局向量级 MoE” 更安全的折中；而 patch / token 级别的稀疏路由虽然在视觉 MoE 与 CNN segmentation MoE 中已有可行性，但它们更多证明的是 “空间路由可以做”，不是说你们现在就应该在 CARE 冲刺期实现一个 patch-wise top-k dense MoE。[9]

在路由器设计上，我建议用 **availability + image feature 的联合 gate**，而不是纯 availability gate。纯 availability gate 的优点是稳定，但它会退化成 “每种模态组合固定走一套专家”，无法吸收同一组合内部的中心风格差异与病灶异质性；而 availability 与局部图像特征联合后，router 才有机会在 “同样都是 LGE-only” 这一组内部，区分清晰 scar、噪声 scar、中心风格伪影等不同难度。具体做法是：在每个尺度，先对可用模态特征做 masked average pooling 得到 $q^\ell \in \mathbb{R}^{C_\ell}$ ，再把 availability embedding $e(m)$ 拼接进去，通过一个两层 MLP 输出每个字典 expert 的打分；训练时用 soft top-k 或 entmax，推理时取 top-2。这样既能利用 BR2 式 observation indicator，又不会把 router 简化成模态模式查表器。[10]

更正式地写，给定某一尺度的模态特征 $F_{lge}^\ell, F_{c0}^\ell, F_{t2}^\ell \in \mathbb{R}^{B \times C_\ell \times H_\ell \times W_\ell \times D_\ell}$ ，定义 availability mask 为 $m = (m_{lge}, m_{c0}, m_{t2})$ ，其中 LGE 在 CARE MyoPS 中几乎总是存在，因此 $m_{lge} = 1$ 对绝大多数样本恒成立。我们先做 masked pooling：

$$q^\ell = \text{Pool} \left(\frac{m_{lge} F_{lge}^\ell + m_{c0} F_{c0}^\ell + m_{t2} F_{t2}^\ell}{m_{lge} + m_{c0} + m_{t2} + \varepsilon} \right).$$

再定义 gate logits：

$$a_{t,\ell} = \text{MLP}_{t,\ell}[q^\ell \parallel e(m)], \quad t \in \{\text{ana}, \text{scar}, \text{ede}\}.$$

经过 entmax 或 soft top-k 后得到检索系数：

$$\alpha_{t,\ell} = \text{SparseGate}(a_{t,\ell}) \in \Delta^{K_\ell-1}.$$

最后被检索出的尺度表示写成

$$R_t^\ell = \sum_{k \in \mathcal{D}_{sh}^\ell \cup \mathcal{D}_{priv}^\ell \cup \mathcal{D}_{mix}^\ell} \alpha_{t,\ell,k} E_k^\ell(\tilde{F}^\ell),$$

其中 $\tilde{F}^\ell$ 是当前样本所有可用模态特征经 masked fusion 后的输入， E_k^ℓ 是第 k 个 expert block。这样一来，representer 是 expert block 本身，retrieval 发生在空间特征图层面，而不是全局向量层面。这个改写忠实继承了 R2/BR2 的 “表示字典 + 稀疏检索” 思想，但把其适配到了 dense segmentation。[11]

在 decoder 端，我建议 anatomy 与 pathology 解耦而非完全级联。anatomy head 输出的不应只是 hard myocardium，而应是一个 soft union prior，近似预测 MYO $\cup$ Scar $\cup$ Edema 所在区域。这样做有两个理由：第一，CARE 原始标

签语义中病灶会替代纯 myocardium 标签，因此 “scar/edema 必须包含在纯 myocardium 内” 这个约束过硬，容易误伤边界；第二，队内现有 runbook 也明确指出，pathology 会替换部分 myocardium label，因此 containment 更适合用 union prior，而不是用纯 myocardium hard mask 来卡死。对 scar，再单独叠加一个弱 containment 正则，鼓励它不要大面积跑到远端；对 edema，则优先用 T2 conditioned supervision，而不是用所有 no-T2 样本把它当作负类压下去。[12]

如果要给出与现有工程兼容的 tensor 级数据流，一个可实现版本可以写成：输入 ROI shape 统一为 $[B, 1, H, W, D]$ ，分别送入三个 stems 得到 $[B, 32, H, W, D]$ ；四层 encoder 后得到 $\{[B, 32, \cdot], [B, 64, \cdot], [B, 128, \cdot], [B, 256, \cdot]\}$ ；每个尺度经 retrieval bank 变成 anatomy/scar/edema 三套 routed features；anatomy decoder 输出 $P_{\text{union}}, P_{\text{lv}}, P_{\text{rv}}$ ，scar decoder 输出 P_{scar} ，edema decoder 输出 P_{ede} ；最后用 anatomy prior gate 做

$$\hat{P}_{\text{scar}} = \sigma(\text{logit}(P_{\text{scar}}) + \lambda_s \phi(P_{\text{union}})), \quad \hat{P}_{\text{ede}} = \sigma(\text{logit}(P_{\text{ede}}) + \lambda_e \phi(P_{\text{union}})),$$

其中 $\phi(\cdot)$ 可以是软门控而不是硬裁剪。scar 的输出再接一个 component-aware inference rule，只保留心肌 union ROI 周围的高置信连通域，以直接照顾 HD/HD95 对远端 FP 的敏感性。CARE 官方评价用 Dice 与 HD；队内 runbook 也指出 scar 的远端 FP 与 edema 的 topology/remote-FP/HD95 才是现在真正的瓶颈，因此空间先验与检索逻辑比 “再换一次 backbone” 更对症。[13]

数学定义与训练目标

要把 R2/BR2 的 SIP 写成可稳定训练的分割 regularizer，关键不是照抄原文，而是把 “鼓励更 integrative 的 representer” 转化为三个更温和的约束：**实例内 sparsity**、**数据集范围内 coverage**、以及**共享专家不过载不过空载**。原文的 SIP 是围绕跨 source 的 coefficient support 构造的截断惩罚，并在 BR2 中对各 modality dictionary 分别施加；对你们这种小样本 3D 分割而言，直接做离散 support 计数会非常不稳。我建议把它改成下面这个 soft 版本。先定义在一个 mini-batch 上，第 k 个 expert 被某个 path/head 使用的平均门值：

$$u_{t,\ell,k} = \frac{1}{B} \sum_{b=1}^B \alpha_{t,\ell,k}^{(b)}.$$

再定义每个 expert 的 “软 integrativeness” 近似为在一个 epoch 内被多少 availability pattern 或 style cluster 稳定调用的平滑计数。实践里不必真的数中心，而是用 availability pattern $p \in \{\text{LGE}, \text{LGE}+\text{C0}, \text{LGE}+\text{T2}+\text{C0}\}$ 与无监督 style cluster c 的交叉统计近似。于是，一个可训练的 SIP-inspired 项可以写成

$$\mathcal{L}_{\text{sip}} = \sum_{\ell,k} \omega_k^\ell \left[\max(0, \tau_{\min} - \bar{\gamma}_{\ell,k}) \right]^2,$$

其中 $\bar{\gamma}_{\ell,k}$ 是 expert k 在多个 pattern/style 组上的平滑使用覆盖率， $\tau_{\min}$ 是希望它至少被若干组复用的阈值。与其相配套，再加一个 load-balancing 项

$$\mathcal{L}_{\text{lb}} = \sum_{t,\ell} \text{KL}(u_{t,\ell} \| \pi_{t,\ell}),$$

其中 $\pi_{t,\ell}$ 是偏向共享 experts 但不过分平均的目标分布。这样既鼓励 integrative experts 真被跨组调用，又避免 gate collapse 到单个 expert。[14]

总损失我建议写成

$$\mathcal{L}_{\text{total}} = \lambda_{\text{ana}} \mathcal{L}_{\text{ana}} + \lambda_{\text{scar}} \mathcal{L}_{\text{scar}} + \lambda_{\text{ede}} \mathcal{L}_{\text{ede}} + \lambda_{\text{sp}} \mathcal{L}_{\text{sp}} + \lambda_{\text{sip}} \mathcal{L}_{\text{sip}} + \lambda_{\text{lb}} \mathcal{L}_{\text{lb}} + \lambda_{\text{cons}} \mathcal{L}_{\text{cons}} + \lambda_{\text{prior}} \mathcal{L}_{\text{prior}}.$$

其中 anatomy loss 可以用 DiceCE：

$$\mathcal{L}_{\text{ana}} = \text{DiceCE}(P_{\text{union}}, Y_{\text{union}}) + \eta_{\text{lv}} \text{DiceCE}(P_{\text{lv}}, Y_{\text{lv}}) + \eta_{\text{rv}} \text{DiceCE}(P_{\text{rv}}, Y_{\text{rv}}).$$

scar loss 建议采用 DiceCE 减弱 boundary/HD surrogate，但第一轮只对 scar 开：

$$\mathcal{L}_{\text{scar}} = \text{DiceCE}(\hat{P}_{\text{scar}}, Y_{\text{scar}}) + \beta_{\text{bd}} \mathcal{L}_{\text{bd}}(\hat{P}_{\text{scar}}, Y_{\text{scar}}).$$

edema loss 必须是 **T2-masked**：

$$\mathcal{L}_{\text{ede}} = m_{\text{t2}} \cdot \text{DiceCE}(\hat{P}_{\text{ede}}, Y_{\text{ede}}),$$

这里 $m_{\text{t2}} = 1$ 仅对 T2 present 且 edema label 可用的样本生效；没有 T2 的样本既不当 edema-positive，也不当 edema-negative。retrieval sparsity 用

$$\mathcal{L}_{\text{sp}} = \sum_{t,\ell} \|\alpha_{t,\ell}\|_1$$

或 entmax 的隐式稀疏即可，但强度不要过高。若加入完整三模态上的轻量 alignment expert，则 consistency/alignment 项写成 feature-level 一致性，而不是全数据 raw-image 配准。prior loss 则用软 containment：

$$\mathcal{L}_{\text{prior}} = \text{BCE}(\hat{P}_{\text{scar}}, \hat{P}_{\text{scar}} \odot \text{sg}(P_{\text{union}})) + \text{BCE}(\hat{P}_{\text{ede}}, \hat{P}_{\text{ede}} \odot \text{sg}(P_{\text{union}})),$$

其本质是惩罚病灶明显游离于解剖软区域之外。这个总损失与 MyoPS-Net 的 pathology-specific prior 思路一致，也和 BR2 “不做缺失模态插补、只利用观测到的模态与可用监督”相一致。[15]

你特别追问的 source/task 定义，我的推荐是：正式模型不把 source 定义为显式中心，也不定义为 center×modality pattern；source 的可部署等价物应是“当前样本条件”，即 availability pattern 与图像风格共同决定的隐式 source。原因很直接：新中心推理时不该依赖已知中心 ID。更工程化地说，训练时可以用 availability pattern 作为显式分组，并用 features 上的 style clustering 或 domain-adversarial regularization 去吸收中心偏移；但推理时 router 只读可用模态和图像内容，不读中心标签。这样既保留了 R2 的“异质数据源”思想，又避免把模型绑死在训练中心标识上。[3]

一个足够接近 Codex implementation task 的伪代码如下：

```
# x_lge, x_c0, x_t2: [B,1,H,W,D], unavailable modality -> None
# m: [B,3] availability mask
# outputs: union anatomy, scar, edema

f_lge = enc_lge(stem_lge(x_lge)) if x_lge is not None else None
f_c0 = enc_c0(stem_c0(x_c0)) if x_c0 is not None else None
f_t2 = enc_t2(stem_t2(x_t2)) if x_t2 is not None else None

routed_ana, routed_scar, routed_edema = [], [], []
for l in scales:
    fused_l = masked_fusion([f_lge[l], f_c0[l], f_t2[l]], m)
    q_l = masked_global_pool(fused_l, m)
    emb = concat(q_l, avail_embed(m))

    gate_ana = sparse_gate(router_ana[l](emb)) # top-2 / entmax
    gate_scar = sparse_gate(router_scar[l](emb))
    gate_edema = sparse_gate(router_edema[l](emb))

    routed_ana.append(retrieve(dict_shared[l], dict_priv[l], dict_mix[l], fused_l, gate_ana))
    routed_scar.append(retrieve(dict_shared[l], dict_priv[l], dict_mix[l], fused_l, gate_scar))
    routed_edema.append(retrieve(dict_shared[l], dict_priv[l], dict_mix[l], fused_l, gate_edema))

p_union, p_lv, p_rv = dec_ana(routed_ana)
p_scar = dec_scar(routed_scar)
p_edema = dec_edema(routed_edema)

p_scar = anatomy_gate_scar(p_scar, p_union)
p_edema = anatomy_gate_edema(p_edema, p_union)

loss = L_ana + L_scar + m_t2 * L_edema + L_sparse + L_sip + L_lb + L_prior
if use_alignment_expert and is_complete_case:
    loss += L_align
```

这个版本的核心特征只有三个：模态特异编码、共享/私有字典检索、条件监督。它没有把“换 backbone”“加 mask channel”“换一个 loss”单独包装成方法故事，而是用 retrieval 原则把它们收束到一个正式模型里。[11]

最小降级版本与和现有基线的区别

如果你只做 7-10 天可交付的最小版，我建议把正式架构降到 **SRR-MyoPS-Lite**：保留 LGE / C0 / T2 三个 stems，保留 anatomy / scar / edema 三个 heads，保留 availability-aware gate，但把“字典”缩成每尺度 1 个共享块 + 每模态 1 个私有块；router 只在 head 级别输出三组 mixture weights，不做真正的 top-k 稀疏；SIP-inspired regularizer 只保留 load balancing 与跨 pattern coverage 两项；alignment 完全关闭。这样做的好处是：第一轮实现，你们代码里更像是在 nnU-Net encoder 之上插了一个 shared/private gated fusion 层，而不是从零写一个 MoE 框架。这个最小降级版仍然保留方法的“故事骨架”：不是 late fusion 的拼装，而是 selective retrieval。[16]

与 MyoPS-Net 相比，SRR-MyoPS 的关键区别不是“也有 pathology-specific decoder”，而是把“灵活模态组合”从固定融合规则提升为条件检索规则。MyoPS-Net 假设的是“给定一组模态，学会灵活融合它们”；SRR-MyoPS 则假设“给定一组模态与当前样本特征，从共享与私有表示字典中稀疏检索最可信的子表示”。这意味着你们不是在 fixed fusion graph 上做 dropout，而是在 feature bank 上做 conditional retrieval。第二个区别是监督语义：MyoPS-Net 并不面向 CARE 这种“no-T2 不能解释成 edema-negative”的缺失监督机制，而你们的方法把 edema loss 显式写成 T2-conditioned masked loss。第三个区别是中心异质性：MyoPS-Net 强调 practical missing-sequence scenarios，但没有把 center-coupled missingness 当成显式设计对象；SRR-MyoPS 则把 availability pattern 与 style

shift 一起吸收进 router/regularizer。[17]

与 U-MyoPS 相比，SRR-MyoPS 的区别在于先检索后必要时局部对齐，而不是先配准后统一融合。U-MyoPS 的故事是把所有序列拉到 LGE common space，再用 myocardium prior gate 约束 pathology segmentation；SRR-MyoPS 则认为在 CARE 当前训练分布中，最致命的不是“全样本都缺一个 registration module”，而是“训练和验证的模态可用性与中心缠绕在一起，导致统一表示学错 shortcut”。因此配准只作为 complete tri-modal 子集上的条件 expert 出现，且放在 feature level，而不进入主故事。[5]

与 CineMyoPS 相比，SRR-MyoPS 在 cine 端的关系应该写成“原则一致，实例不同”。CineMyoPS 在 ED reference 空间里整合 motion / anatomy / texture，强调 warped features 与 time-series aggregation；你们若做单帧 wrapper，只剩下“纹理分割”这一层，自然不等价。我的建议是：针对 Cine 单独写 **Temporal Representation Retrieval for Cine CMR**，但在论文总引言中说它与 SRR-MyoPS 共享同一原则——都是从当前可用的证据中检索可靠表示。这样比生拉硬拽出一个 4D+3-seq 巨型统一网络安全得多。[18]

与 HeMIS / ModDrop 一类缺模态方法相比，SRR-MyoPS 的差别也要写清楚。HeMIS 的核心是把各模态映射到共享 latent space 后取统计量，如 mean/variance，再后续分割；ModDrop 的核心则是用训练期随机丢模态，让融合网络对缺失鲁棒。它们都很有用，但都更像“鲁棒融合策略”，而不是“部分共享的表示选择原则”。R2/BR2 之所以适合做你们的正式故事，正因为它处在全共享与全独立之间：既不要求所有样本都完全共用一个 latent，也不要求每种 pattern / center 单独训练一套模型，而是允许某些 representer 被很多 source 共享、某些只被少数 source 调用。CARE 正是需要这个层级的表达能力。[19]

配准、Cine 统一性、工程计划与消融

关于“配准是否进正式版本”，我的结论很明确：不是 must-have，而是 optional ablation，且只有在 complete tri-modal 子集的误差诊断明确证明错位是主因时才升级为条件 expert。原因有三层。第一，CARE 官方就把 missing sequences、multi-center variations 与 spatial misalignments 并列为挑战，但这并不意味着三者在你们当前阶段的重要性等权；队内 runbook 已明确指出 edema 关键失败区是 T2-present / CenterC / topology / remote-FP，而不是“所有样本都先缺一个配准器”。第二，U-MyoPS 的完整故事确实需要 registration-before-fusion，但它预设的是 stage bridge 完整且多序列尽量可用；这和你们当前项目状态并不一致。第三，late fusion 本身就比较 raw-image early fusion 更能减小轻度未对齐带来的破坏，因此在 7-10 天预算里，先把 fusion 改成检索式 late fusion，收益更大、更稳。定量诊断标准我建议定成：只看 complete tri-modal 子集，若加入一个 feature-level LGE-reference alignment block 后，edema/scar 的 HD95 和单病例远端 FP 都有稳定下降，而 Dice 不明显回退，那才值得纳入；否则冻结。[20]

Cine 是否用同一 retrieval 原则统一，我的判断是：原则上可以统一，论文上不应强行统一成一个大模型。在 Cine 里，最合理的映射是：ED frame 特征作为 shared temporal anchor，若干关键帧 anatomy / texture / motion cues 作为可被检索的 temporal representer dictionary，router 则根据 frame quality、时间位置和 motion saliency 去选择关键帧。形式上，这和 BR2 的“只利用当前观测到的模态块”很像，只不过 modality 变成了 temporal evidence type。但在剩余时间里，最划算的写法仍然是两条线：MyoPS 作为 **availability-aware pathology-specific retrieval**，Cine 作为 **anatomy-first temporal retrieval**。这是因为 CineMA 官方资源已经明确支持 cine CMR foundation model、给出 MIT 许可，并在 Hugging Face 提供 mit 许可模型卡；而 CineMyoPS 官方仓库虽有代码并在 README 中给出 Baidu 云模型入口，但当前页面未显示清晰 license 区段，且其主故事基于完整的 motion/anatomy/pathology end-to-end 训练。冲刺期更适合“借 anatomy prior + 自己做轻量时序聚合”，而不是整个重写 CineMyoPS。[21]

7-10 天工程计划我建议分成四个阶段，每个单 job 不超过 8 小时。第一阶段先做 **标签与路由语义校正**：把官方原始 label value 的双向映射、导出 QA、以及 MyoPS/Cine 分支的一包三榜语义全部写成单元测试；你们当前 CARE repo 已明确指出一个 zip 同时返回三个指标，且 local class proxy 不等同 hosted metric，这一步如果没做，后续任何模型改动都有可能因为 wrapper 偏差而失真。第二阶段实现 **SRR-MyoPS-Lite**：先上三 stems、共享/私有 gated fusion、三个 heads、T2-masked edema loss、union anatomy prior 与 scar component-aware inference；停止门是 scar 远端 FP 与 edema non-T2 shortcut 明显缓解，哪怕 Dice 只小涨。第三阶段做 **SIP-inspired regularizer 与 modality dropout**：若 gate collapse 或 expert under-training 明显，再加 coverage / load balancing；若不稳定，则回滚到 soft gate，不强推 top-k。第四阶段单独做 **Cine temporal retrieval**：优先利用外部 cine anatomy prior 做 ED+ 关键帧聚合，先追 myocardium_cinemyops，不要先追 cine 下的 scar/edema 全故事。你们当前 repo 里的 status 也显示，MyoPS scar/anatomy baseline 已相对稳定，edema 与 Cine 才是主缺口。[12]

消融矩阵不必铺得很大，但必须能把“故事核心”打出来。我建议至少做下面七个对照：第一，**unified channel concat**，也就是最朴素的多通道基线；第二，**conditional loss only**，只做 T2-masked edema supervision，不做 retrieval；第三，**modality-specific encoders**，但无 shared/private retrieval；第四，**+ retrieval gate**；第五，**+ SIP-inspired regularizer**；第六，**+ anatomy prior / scar containment**；第七，**+ optional alignment expert**。其中第四与第五是你们正式故事和“已知组件拼装”的分水岭：如果第四步开始 scar/edema 的 HD 与远端 FP 就明显好于第三步，说明检索式 shared/private 原则抓住了数据机制；如果第五步只带来小幅稳定性提升，也足够，因为它本来就应该“防 collapse 的 regularizer”，而不是独立卖点。[22]

把这些模块和 metric 逐一对应起来，逻辑会更清楚。LGE 主 scar 分支、scar containment、component-aware inference，主要作用于 myops_scar，尤其是 HD / HD95；T2-conditioned edema supervision、T2 私有 expert、availability-

aware router，主要作用于 myops_edema；anatomy union prior 会同时帮助 scar 与 edema，但对 edema 的远端 FP 更关键；Cine 侧的 ED reference、关键帧检索、frame-wise anatomy prior 与 temporal consistency，主要对应 myocardium_cinemyops。这一点和官方任务定义是完全一致的：MyoPS 里 scar 对应 LGE，edema 对应 T2；CineMyoPS 里目标位于 ED frame 的 cine 序列。[23]

失败模式也应预先写进故事。第一类是 **gate collapse**：所有样本都走共享 expert，或者 T2 expert 永远只在少数样本上响；应对方式是 soft load-balancing 和 warm-start。第二类是 **expert under-training**：top-k 过早太硬；应对方式是前若干 epoch 用 entmax / soft gate，再逐步变稀疏。第三类是 **T2 expert overfit**：只在 80 个 complete case 上训练 edema，容易学到中心样式；应对方式是共享 expert 保底、强 augmentation、以及不显式使用中心 ID。第四类是 **center leakage**：availability 本身就是中心 proxy；应对方式是 router 输入里只允许 availability 与图像特征，不读中心标签，且可加轻量 domain-adversarial feature regularization。第五类是 **misalignment**：若 tri-modal 个案上明显错位，late fusion 仍会被误导；这时才启用条件 alignment expert。第六类是 **scar false positive**：这是 HD/HD95 的头号风险，应让 scar 先吃 anatomy prior 与 component rule。第七类是 **temporal label mismatch**：cine raw label 只对应 reference geometry，不能把所有非参考帧都当 pathology 监督，这就是为什么 Cine 要围绕 ED reference 与 time-series evidence，而不是逐帧硬监督。[24]

高价值资源审计

下面这组资源不是“论文清单”，而是我认为对当前冲刺最有价值、且能支撑正式方法故事的资源分级。表中“可复用方式”只分为直接复用、借模块、借损失/正则、只借思想四种。

资源	年份与出处	官方论文	官方代码 / HF / 权重 / 许可证	与 CARE 的匹配	3-5 天最小实现	主要风险	可复用方式
CARE 2026 Myocardium 官方赛题页	2026, CARE	官方赛题页已给出数据构成、标签值、三榜定义	无代码；是任务定义源	最高，定义任务本身	当日可完成 label/export/metric 统一	无	直接复用任务定义 [25]
Yuukias/CARE2026Challenge	2026, Challenge 前项目仓库	无	GitHub 仓库；当前明确 benchmark runbook、上传语义与失败区	最高，直接对应现有 pipeline	当日可做 runbook 与提交 QA	不是方法仓库	直接复用工程骨架 [12]
MyoPS-Net	2023, Medical Image Analysis	arXiv / MedIA DOI 可见	官方 GitHub, MIT；未见公开 release 权重	高，可直接借 pathology-specific + anatomy prior 故事	3-5 天可写成 SRR-MyoPS-Lite 骨架	原实现面向五序列，照搬性价比低	借结构与损失思想 [26]
U-MyoPS	2023, IEEE TMI	arXiv 可见	官方 GitHub, Apache-2.0；未见 releases	中高，适合作 alignment expert 来源	3-5 天只能做 feature-level 局部 ablation	完整 Stage1 → Stage2 重写太重	借对齐与 prior-aware 思想 [27]
CineMyoPS	2025, IEEE TMI	arXiv HTML 可见	官方 GitHub；README 提供 Baidu 云训练模型入口；当前页面未见清晰 license 区块	高，是 cine 正统故事来源	3-5 天内不建议全复现，但可借 ED/motion/time aggregation 机制	端到端重写成本高；license 信息不完整	借时序机制与叙事 [28]

资源	年份与出处	官方论文	官方代码 / HF / 权重 / 许可证	与 CARE 的匹配	3-5 天最小实现	主要风险	可复用方式
Representation Retrieval Learning	2025, arXiv	arXiv PDF	当前检索未见官方代码或 HF	高, 适合作统一原则	2-3 天可把其抽象改写成 segmentation-native router/dictionary	不能直接外推其理论到 dense segmentation	只借原则与正则形式 [29]
HeMIS	2016, MICCAI / arXiv	arXiv 可见	当前检索未确认官方代码/HF	中高, 是缺模态共享 latent 的经典下界	半天就能作为思想对照写进 ablation	过于均值化, 不足以处理 center-coupled missingness	只借思想, 作为 baseline 对照 [30]
ModDrop	2015, arXiv	arXiv 可见	当前检索未确认官方代码/HF	中, 适合作训练技巧	半天可实现 modality dropout	不能解释 partial sharing	借训练策略 [31]
CineMA	2026, Communications Medicine	GitHub 页面给出 Nature 链接; HF 模型卡与 repo 一致	官方 GitHub, MIT; 官方 Hugging Face, License: mit; 提供预训练与 fine-tuned 模型	高, 最适合做 cine anatomy prior	1-3 天能做 adapter smoke, 3-5 天能做关键帧 anatomy prior	官方分割入口默认单帧, 需要你们自己加 temporal aggregation	直接复用外部 anatomy prior [32]
CNN / 视觉 MoE 的 dense prediction 证据	2021-2026, NeurIPS / CVPRW / AAAI / MICCAI	V-MoE, PatchConvMoE, TA-MoSC, MoME 等主源可见	代码/许可并不都成熟, 且不应作为本次主依赖	中, 用于证明 spatial routing 与 expert balancing 可行	不建议直接接仓库	过重且容易偏题	只借论证与小模块形式 [9]

从这个审计表可以直接推出资源策略：**MyoPS 仅借 MyoPS-Net 的结构思想与 R2/BR2 的原则；Cine 优先直接使用 CineMA；U-MyoPS 只在 alignment 被证明确有必要时才借局部模块；HeMIS/ModDrop 作为对照，不作为最终故事。**这与当前项目仓库对现状的判断也是一致的：nnU-Net 仍是 operational baseline，MyoPS-Net 与 U-MyoPS 更像 negative evidence / mechanism sources，而 edema 与 Cine 才是增益空间所在。[12]

最终判断与边界

最终的 GO / NO-GO 结论如下。**GO：把 R2/BR2 作为正式方法故事的主轴原则。**但这里的“GO”必须带限定词：你们应该宣称的是“受 R2/BR2 启发的 selective representation retrieval segmentation framework”，而不是“我们把 R2 理论直接推广到了 dense CMR segmentation 并保持原定理成立”。如果以这个表述推进，它会比当前“availability-aware pathology-specific fusion”更鲜明，因为后者容易被读成 known components 的拼装；而“selective representation retrieval”则给出了一个更强的 shared/private representation selection 原则，能把 modality-specific stems、pathology-specific decoders、T2-masked edema supervision、anatomy prior 和 optional alignment 统一到一个正式模型中。[29]

NO-GO：把原始 R2/BR2 的线性 learner、显式 source coefficient support 与原型 SIP 直接搬进分割网络。这会让故事显得像“把表格数据方法硬套到 3D 分割”，而且在 7-10 天预算内工程风险过大。若你们最终发现 retrieval gate 难以稳定训练，最强替代故事不是回到“统一 concat + 多个 loss”，而是退回到 **shared/private gated fusion** 版本：保留模态私有编码与 pathology-specific heads，把 router 从 sparse retrieval 退化成 soft mixture。这样仍然保住方法主线，只是把检索做得更软、更工程友好。[33]

如果要把这份蓝图转写成 Codex 实现任务，我建议第一阶段就把正式标题固定成下面这个版本：**Selective Representation Retrieval for Partially Observed Multi-sequence Cardiac MR**。MyoPS 小标题写成 **availability-aware pathology-specific retrieval**，Cine 小标题写成 **anatomy-first temporal retrieval**。这样一来，你们既不会为了“统一”而过度设计，也不会退回到“只是多加几个 mask 和 loss”的弱故事。[34]

开放问题与限制

有三点需要明确标注为当前证据边界。第一，CineMyoPS 官方仓库当前页面能确认有代码，并在 README 中给出 Baidu 云训练模型入口，但我这次检索没有在其仓库页面上确认清晰 license 区块，因此若后续要直接复用其中代码或权重，仍需在实现前做一次许可核验。[35]

第二，R2/BR2 当前公开论文的理论及主要实验建立在 heterogeneous regression/classification / block-missing integration 场景；把它迁移到 dense CMR segmentation 是一个方法改写，不是原定理的直接应用。因此论文写作时应把 “theoretically motivated” 与 “segmentation-native adaptation” 区分开，避免过度宣称。[29]

第三，当前最稳的 cine 外部资源是 CineMA，因为其 GitHub 与 Hugging Face 都清楚标注了 MIT 许可并提供预训练/微调模型；但它默认的分入口仍然是单时相 SAX 任务，这意味着你们在 Cine 上的真正增益，仍取决于自己补上的 ED reference + 关键帧聚合 + temporal consistency 部分，而不是仅仅 “接一个 foundation model”。[32]

参考来源

以下编号与 Result4-raw.pdf 中的正文脚注编号一致。

- 1, 8, 13, 20, 23, 24, 25: [CARE-Myocardium | CARE](#)
- 2, 3, 7, 10, 11, 14, 16, 22, 29, 34: [Representation Retrieval Learning for Heterogeneous Data Integration](#)
- 4, 15, 17, 26: [\[2211.03062\] MyoPS-Net: Myocardial Pathology Segmentation with Flexible Combination of Multi-Sequence CMR Images](#)
- 5, 27: [Aligning Multi-Sequence CMR Towards Fully Automated Myocardial Pathology Segmentation](#)
- 6, 18, 28: [CineMyoPS: Segmenting Myocardial Pathologies from Cine Cardiac MR](#)
- 9, 33: [Design and Behavior of Sparse Mixture-of-Experts Layers in CNN-based Semantic Segmentation](#)
- 12: [GitHub - YuukiAS/CARE_Challenge](#)
- 19, 30: [HeMIS: Hetero-Modal Image Segmentation](#)
- 21, 32: [GitHub - mathpluscode/CineMA: A Vision Foundation Model for Cine Cardiac Magnetic Resonance Imaging](#)
- 31: [ModDrop: adaptive multi-modal gesture recognition](#)
- 35: [GitHub - NanYoMy/CineMyoPS](#)