

CARE 2026 Myocardium 定向深度研究报告

任务现实与问题根因

先给结论。你们不应该放弃 SRR dictionary 这条线，但也绝对不应该再把它当成“最终分割器”的主体。基于你给出的现状，我的判断是：当前 SRR 的确已经学到了“该看哪种证据”的一部分东西，所以不同 dictionary 结构会稳定改变 scar 与 edema 的相对表现；但它还没有学到“病灶应该怎样在空间上形成”的机制，因此它只能提高证据选择，无法把这些证据组织成低远端假阳性、低 component burden、低 HD95 的病灶形状。公开的 MyoPS 与 CARE 路线里，真正接近强成绩的方法，几乎都不是“全图一次性 dense head 直接出 scar/edema”，而是显式或隐式地先做 anatomy localization、再做 pathology refinement，或者使用 coarse-to-fine、region-based crop、anatomy-guided pathology 的系统设计。MyoPS 2020 冠军方案就是 coarse-to-fine；2024 CARE 的 MS-CaRe-CNN 是两阶段 3D cascade；公开的 CARE2024-MyoPS 代码仓库也是 coarse-seg 再 fine-seg 的双阶段区域训练管线。最新公开的 CARE-MyoPS 2025 leaderboard 也表明第一梯队 scar 与 edema 的 Dice 已经进入明显高于普通 dense baseline 的区间，这类成绩靠字典结构微调基本不可能摸到。[1]

从 dense segmentation 的角度看，现有 SRR 的核心短板不是“没有用到 LGE/T2/C0”，而是“没有 lesion proposal”。HeMIS、mmFormer、PASSION、任务条件 MoE、CLoE 这一类缺模态文献，解决的是在模态不齐全时如何保持表示稳健、如何减少专家之间的漂移、如何平衡不均衡 missingness；它们能提升特征融合与决策一致性，但并不天然提供病灶候选生成、远端小岛清除或 component-level 可信度控制。CLoE 之所以值得注意，恰恰是因为它已经开始把“小前景结构上的 expert consistency”单独拿出来约束，这说明仅靠 feature fusion，本身无法解决小病灶与假阳性问题。你们现在看到的“relative signal 有、absolute performance 低”，与这条文献脉络高度一致：SRR 已经在做 better feature selection，但还没有做 lesion formation。[2]

再往前推一步，scar 与 edema 也不该由同一个最后 dense head 平权地产生。MyoPS-Net 虽然是统一框架，但它用的是 pathology-specific output branches，并且结合 myocardium prior 与 scar-edema 关系约束；U-MyoPS 也不是简单拼接，而是先把多序列对齐到共同空间，再以 myocardium 作为 pathology 的空间先验。CARE 这类数据上，scar 的本质更接近 LGE-driven、体积小、错误代价高的“精细候选筛选”；edema 则更接近 T2-driven、范围弥散、边界模糊、对 recall 更敏感的“软区域生成”。把二者压进同一个终端 dense head，往往意味着 scar 会被 edema 的大区域统计淹没，而 edema 又会被 scar 的小目标稀疏性牵着走。[3]

你们最近 compactness loss 的失败，其实反过来证明了这一点。component compactness、containment、center balance 之类约束，在 proposal 不可靠时只是在对“已经错位的 logit 场”做几何惩罚。Prior-based loss 的 benchmark 明确指出，低层 prior loss 往往更稳，高层结构先验是否有效强依赖数据特性；而 blob loss、ICI loss、surface/HD 类损失之所以对小目标有帮助，是因为它们更接近 instance detection、中心与边界的训练目标，而不是单纯把概率图压得更圆。换句话说，如果 proposal 召回和负空间判别没有先建起来，compactness 往往只能以牺牲 Dice 来换一点 HD。你们实验里“HD95 下降但 scar Dice 掉、edema component burden 仍高”正符合这个模式。[4]

公开方法真正提供的可迁移机制

最值得吸收的第一类机制不是“多模态怎么拼”，而是“解剖先验如何转化为病灶候选”。MyoPS 2020 冠军方案先用粗阶段分割环形 myocardium、LV、RV，再把粗结果作为第四通道送进 fine-stage nnU-Net；MS-CaRe-CNN 在 CARE2024 上同样先预测 anatomy，再把 anatomy prediction 与原图拼接送入第二阶段做 tissue viability refinement。你们如果要追平甚至超过本地 nnU-Net baseline，那么必须承认一件事：在 CARE 这种缺模态、中心漂移、小病灶并存的数据上，“先缩小错误搜索空间，再做 pathology discrimination”不是老派技巧，而是目前公开强系统的共识。[5]

第二类可迁移机制是 anatomy-guided pathology exchange。APEx 的价值不在于 PET/CT 或胸片本身，而在于它把 anatomy query 与 pathology decoder 直接交织，迫使病灶预测从“脱离身体结构的异常纹理识别”升级为“带解剖语境的异常区域推断”。CARE 的 scar 与 edema 也同理：真正该进入 proposal 的不是“某个像素像不像 scar”，而是“这个像素在 myocardium 内、靠近哪一层壁、与 LV/RV 边界关系如何、周围相邻像素是否形成 plausible lesion morphology”。这正是 current SRR 缺失的一环。[6]

第三类机制是 prototype 与 memory，不是拿来做法哨 retrieval，而是拿来做法 class-specific discrimination。Sim-MPNet 这类工作把 prototype memory bank 当成类别细粒度特征的存储器；Instance-adaptive Prototype Learning 则强调 prototype 不能只是一套全局均值，而需要对当前输入自适应；MSPA 说明 prototype alignment 能同时增加类内紧致与类间分离。把这些思想放进 CARE，最自然的落点不是“检索哪种模态特征”，而是为 scar 和 edema 分别维护一组正原型与负原型，让 logit 由“靠近病灶原型、远离远端假阳性原型”的相似度差决定。这样 dictionary 才真正从 feature selector 变成 pathology discriminator。[7]

第四类机制是显式 hard negative mining。ULDor 和 Lesion-Harvester 都说明，对于 lesion-centric 任务，假阳性不是训练噪声，而是必须被单独采样、单独建模、反复回灌训练的对象；前者用 hard negative example mining 降低 false positives，后者更进一步把 proposal generator 与 hard-negative suppression loss 结合起来迭代更新。CARE 上的 remote false positives、本体外小岛、LGE 假高信号、T2 噪声，都非常适合这一套思想，但要注意 edema 的 hard negative 只能来自“安全负样本”，不能从 no-T2 myocardium 里暴力挖。[8]

第五类机制是 coarse-to-fine lesion segmentation。PANet 与 Global Guidance Network 都不是简单二段式裁剪，它们的核心是先学 ROI attention 或 global guidance，再在保持上下文的条件下做细化。对 CARE 而言，这很重要，因为你们不能靠 hard ROI deletion 把远端全部裁掉，否则容易漏掉小 scar；真正合理的做法是 soft ROI、dilated ROI、distance map 与 uncertainty 一起控制“候选区域的优先级”，而不是对空间做一次性二元切断。[9]

主方案

我认为最值得投入的主方案，是把现有 SRR 升级成一个 **共享证据干线加病种专属 proposal dictionary 再接 soft-cascade refinement** 的系统。换句话说，SRR 继续保留，但身份变成“证据组织器”，不再负责最终 dense segmentation。

科学动机上，这个设计同时吸收了 MyoPS-Net 的 pathology-specific 分支、U-MyoPS 与 APEX 的 anatomy-guided 思想、MyoPS2020 冠军与 MS-CaRe-CNN 的 coarse-to-fine 结构、以及 prototype 与 hard-negative mining 文献对小病灶与假阳性问题的处理方式。它的关键不是把 network 再做复杂，而是明确分离三个问题：第一，哪些模态证据可用；第二，哪些位置像候选病灶；第三，候选病灶在局部高分辨率下如何形成医学上可接受的 mask。[10]

CARE 数据对应关系非常直接。共享干线只负责把 LGE/C0/T2 以及缺模态 mask 编进统一证据场 F ，并输出 anatomy prior P_{myo} 、scar evidence map E_{scar} 、edema evidence map E_{edema} 与不确定性 U 。scar proposal dictionary D_{scar} 只在 scar-available case 上更新，主信号来自 LGE，辅以 C0 的结构边界；edema proposal dictionary D_{edema} 只在 T2-present case 上做正原型学习，no-T2 case 只能参与 anatomy、一致性与安全负样本学习，不能把心肌内未标注区域塞进 edema negative。这样做既顺着你的 missingness 结构，也避免把 shift 直接学成错误监督。[11]

在架构上，我建议把 proposal 显式写成相似度差分，而不是继续依赖普通卷积 head 自己“领悟”负空间。令 $k \in \{\text{scar}, \text{edema}\}$ ，proposal pixel p 的正负相似度写成

$$s_p^{(k,+)} = \max_{c \in D_k^+} \cos(f_p, c), \quad s_p^{(k,-)} = \max_{c \in D_k^-} \cos(f_p, c).$$

然后定义 proposal logit 为

$$\ell_p^{(k)} = \frac{s_p^{(k,+)} - \lambda_k s_p^{(k,-)}}{\tau_k} + \alpha_k E_p^{(k)} + \beta_k P_{\text{myo},p} - \gamma_k d_{\text{remote},p},$$

其中 $d_{\text{remote},p}$ 不是硬裁剪，而是相对于 myocardium neighborhood 的距离惩罚。最终 soft proposal gate 为

$$G_p^{(k)} = \sigma(\ell_p^{(k)}) \cdot (1 - U_p^{(k)}).$$

这个公式的意义很重要：病灶不是“像正样本”就够，而是要“更像正样本、明显不像负样本、且处在合理的解剖邻域中”。这一步就是把 retrieval 真正升级为 lesion proposal。它与 Sim-MPNet 的类别 memory、MSPA 的 prototype 对齐、Lesion-Harvester 的 hard negative suppression 在思想上是一致的，但你们这里是 first-party、CARE-native 的实现。[12]

proposal 之后不做硬删除，而是做 soft cascade refinement。对 scar，用比较小但更高分辨率的 myocardium-neighborhood crop；对 edema，用更大的 dilation box 与更强的上下文保留。具体地，可以对 proposal 的阈上区域做膨胀后取框，并把 proposal gate、到 endocardium/epicardium 的距离图、以及 anatomy prior 一起喂给 refinement head：

$$\tilde{F}^{(k)} = \text{Crop}(F, \text{BBox}(\text{Dilate}(G^{(k)} > \theta_k, r_k))) \oplus G^{(k)} \oplus D_{\text{endo/epi}} \oplus P_{\text{myo}}.$$

scar refinement head 应该偏“小体积高精度”，我建议更深的局部判别器、较强负原型约束、较高 proposal threshold；edema refinement head 应该偏“高召回、模糊边界建模”，我建议较大 receptive field、较低 threshold、显式 boundary uncertainty 分支。最终 scar 与 edema 可以在最后做联合 softmax，也可以维持双二元头再用规则映射回官方标签，但 proposal 与 refinement 一定要分病种。[13]

scar-edema 关系不应写成硬规则。我建议只做 **低不确定度条件下的软不对称约束**：当 edema 头在 T2-present case 上有高置信度时，scar 若离 edema 支撑区过远则受轻惩罚；反过来，edema 不必被硬性要求包住 scar，因为慢性 scar 或中心偏移都可能破坏这种关系。可以写成

$$\mathcal{L}_{\text{scar} \rightarrow \text{edema}} = \frac{1}{|\Omega|} \sum_p \hat{y}_p^{\text{scar}} \cdot \max(0, \delta - \text{Dilate}(\hat{y}_p^{\text{edema}})_p) \cdot (1 - U_p^{\text{edema}}),$$

并且只在 T2-present、edema uncertainty 低的 batch 上生效。这样医学先验是“倾向”，不是“铁律”。这一点与 MyoPS-Net 的 inclusiveness 思路一致，但更适合你们现在的缺模态现实。[14]

实现复杂度方面，这个主方案是中高复杂度，但在三到五天内完全有机会做出第一版，因为你们已经有 SRR 干线、缺模态 mask、病种分头与标签逻辑。新增的核心模块只有四个：病种 proposal dictionaries、negative prototype memory、soft ROI crop/refinement、以及安全负样本采样器。它最大的风险不是代码量，而是 prototype collapse 与 proposal 过严造成 recall 崩塌。成功指标则不应只看 Dice，而应同时看到三个现象：GT-positive case 的 lesion-wise recall 明显上升；心肌外 false-positive ratio 明显下降；median component count 与 HD95 同时下降。如果 Dice 上升但 component burden 不降，说明 proposal 还只是热力图增强；如果 component burden 降了但 recall 崩，说明 negative prototype 或 proposal threshold 过强。[15]

负空间学习、紧致性替代与训练日程

我认为“负空间学习”非常适合 CARE，而且应该成为下一阶段的显式模块。当前最该补的不是更多正原型，而是更系统的负原型：心肌外背景、正常 myocardium、LV/RV blood pool、LGE 高亮伪影、T2 噪声纹理、以及 proposal stage 经常误报的远端小岛。对 scar 来说，这些负类几乎都可以安全使用；对 edema 来说，必须区分安全负样本与不安全负样本。安全负样本包括心肌外区域、血池、在 T2-present case 中离 GT edema 足够远的 myocardium，以及高置信度 artifact 区；不安全负样本则是 no-T2 case 内的 myocardium，因为它们可能只是未标注 edema。[16]

训练目标可以直接写成 margin-style prototype discrimination。对病种 k 的安全负样本集合 $\Omega_{k,\text{safe}}^-$ ，定义

$$\mathcal{L}_{\text{neg}}^{(k)} = \sum_{q \in \Omega_{k,\text{safe}}^-} \max(0, m_k + s_q^{(k,+)} - s_q^{(k,-)}).$$

正样本端再配一个对称的 margin loss：

$$\mathcal{L}_{\text{pos}}^{(k)} = \sum_{p \in \Omega_k^+} \max(0, m_k^+ - s_p^{(k,+)} + s_p^{(k,-)}).$$

scar 的 hard negative mining 可以积极一些，直接从当前预测的高置信 false-positive component 回灌；edema 则保守，优先从心肌外 FP 与 T2-present 的远离 GT 区采样。这样既能打 remote FP，又不会把真实小 scar 或潜在 edema 误杀成负样本。Lesion-Harvester 与 ULDor 的经验非常契合这里的逻辑。[17]

当前 compactness loss 失败，我的解释是它被放在了错误的时机和错误的空间尺度上。在全图 dense head 阶段，component penalty 和 soft containment 会迫使网络“少报”，却无法告诉网络“应该保留哪个 component”；于是模型最容易学到的捷径是收缩疑似 lesion 区，把 recall 砍掉来换 HD95。更合理的替代，不是再堆一个更强的几何 loss，而是把几何约束移到 refinement stage，并使用适合小病灶的 compound loss。scar refinement 我建议用 Dice 或 Focal-Tversky 作为主体，再叠加 blob loss 或 ICI loss 做 instance-level detection，以及 generalized surface loss 或 regional HD loss 处理边界与远端 component；edema refinement 则以 DiceCE 或 DiceFocal 为主体，叠加 surface/distance-map loss 与 uncertainty-weighted containment，减少 diffuse lesion 被过度收缩。Prior-loss benchmark、blob loss、ICI loss、generalized surface loss、distance-transform map 文献都支持这种“分类损失加实例加边界”的组合，而不支持在 proposal 缺位时单独加高层形状约束。[18]

训练 schedule 上，我不建议把 dictionary、proposal、refinement、compactness 一锅煮。更强的 schedule 应该分三阶段加一个短联合微调。第一阶段是 evidence warmup，目标只放在 anatomy prior、scar evidence、edema evidence 与 missing-modality robustness，上法应更接近 PASSION 和 CLoE 的思想：按真实缺模态分布做 modality dropout，edema dense loss 只在 T2-present batch 上启用，其余 batch 只回传 anatomy 与 shared evidence 一致性损失。第二阶段是 proposal learning，这时部分冻结 SRR 低层与 anatomy 分支，只训练 D_{scar} 、 D_{edema} 、negative prototype memory 与 proposal gate，让模型先把 recall 做出来，再逐步加入 hard negative replay。第三阶段是 refinement learning，proposal 主体冻结或半冻结，训练病种专属 refinement heads，并在这里才启用实例级与边界级损失。最后的联合微调再用低学习率放开上层 block，对 proposal threshold、uncertainty calibration 与 scar-edema soft relation 做小幅校准。PASSION 提醒我们 missingness 的优化速度会失衡，CLoE 提醒我们小前景需要 region-wise consistency；你们现在缺的是把这两件事分时完成，而不是同时训练互相拉扯。[19]

如果把下一轮 Codex 任务限定在 12–24 小时，我建议把目标压缩成一条可执行流水线。前 4–6 小时做 evidence warmup 单折训练；接下来的 6–8 小时训练 scar/edema proposal dictionaries 与 hard-negative replay；最后 4–6 小时训练 refinement，并用一小段 2–4 小时的低学习率联合微调做校准。这里真正该被记录的 gate 不是“Dice 有没有多一点点”，而是三类中间指标：proposal recall、心肌外 FP 比例、component 数。只有当这些中间量明显改善时，Dice 才有可能追上 nnU-Net。否则继续加 loss，只会让 current SRR 在低分区间内更换失败形态。[20]

备选路线与外部资源判断

如果主方案在工程上来不及，最稳的备选方案不是继续试 dictionary 变体，而是直接做一个 **CARE-native 的 anatomy-first、region-based coarse-to-fine cascade**。它的思想更接近 MyoPS 2020 冠军、MS-CaRe-CNN 与 CARE2024 的 region-based nnU-Net/Mamba 管线：第一阶段只做 anatomy 与 myocardium ring；第二阶段在 soft myocardium

ROI 内做 scar/edema segmentation；第三阶段用 hard-negative replay 做 false-positive reduction。这条线的优点是更容易快速逼近 baseline，因为它几乎沿着公开有效路线走；缺点是它对“dictionary 真的带来什么”利用不足，更像是暂时把 SRR 降级成辅助手段。作为备选，它很强；作为长期主线，它不如 proposal-prototype 升级版更有上限。[21]

外部公开资源方面，我的建议是 **可以借代码，不要把下一轮成功押在外部权重上**。MyoPS-Net 有 MIT 许可且代码完整，最有价值的是 pathology-specific decoder、myocardium prior 与 loss 组织；MyoPS2020 冠军仓库是 Apache-2.0，最有价值的是 coarse-to-fine 与粗分割结果作为额外通道送入 fine-stage；APEX 也是 Apache-2.0，它最值得借的是 anatomy-pathology exchange 的 decoder 逻辑；PASSION 代码同样公开且为 Apache-2.0，最值得借的是不均衡缺模态训练调度而不是网络骨架本身。[22]

真正要谨慎的是 challenge rule。公开的 2024 MyoPS++ 页面明确写着外部数据集与预训练模型都不允许；但公开的 2025 CARE-MyoPS 页面又改成允许预训练模型，且 leaderboard 已经公开。因此，对 CARE 2026 来说，当前公开 precedent 是摇摆的：2024 禁止，2025 允许。基于这个不确定性，我不建议把 MedSAM、CLIP、Cine foundation model 或外部 anatomy 权重作为主方案的必要依赖。更好的策略是把系统做成“双轨准备”：核心方案完全能用 challenge 内数据自行训练；如果 2026 规则最终允许外部预训练，再把 anatomy encoder 或 cine anatomy prior 作为可插拔增强件加上去。[23]

我不建议把 synthetic T2 或大规模 pseudo-label fusion 作为下一轮主投入。GenSegNet 在 CARE2024 上用 GAN 加自训练确实拿到过第 4 名，并且相对 nnU-Net 在 precision 上有增益，这说明“补缺模态再分割”并非无效；但在你们当前阶段，它的主要风险是把 edema hallucination 引进系统，而你们最痛的恰恰是 remote FP 与 component burden。换言之，生成式补模态更像第二阶段工具，而不是第一优先级的大改法。[24]

CineMyoPS 与最终决策

CineMyoPS 这条副线，我的判断很明确：暂时不应该继续把主要时间耗在 temporal retrieval 上。公开的 CineMyoPS 论文给出的核心机制不是 retrieval，而是 **motion estimation module 加 anatomy segmentation module 再加一致性约束与时间序列聚合**。这说明 cine-only pathology 推断里，真正决定上限的是“参考帧到其他帧的运动对应关系是否可靠”，以及“motion 与 anatomy 是否共同约束 pathology”，而不是单纯从多个关键帧里找一个更像的上下文。你们当前的结果——anatomy reference control 还能工作，但 keyframe context retrieval 没有超过参考控制——与这条公开路线是吻合的。[25]

因此，Cine 下一步最合理的顺序应该是：先把 reference-frame warping 或显式 motion registration 接进来，把 frame0/reference 的 anatomy prior 传播到全周期；然后再决定是否值得做 scar-specific cine head。若规则允许外部预训练，CineMA 作为 cine CMR foundation model 在 anatomy segmentation 与低数据 setting 下有价值，可以继续保留为 anatomy reference control 的候选骨架；但在 MyoPS 主线没有建立 proposal/refinement 之前，我不建议把 CineMA 扩展成新的主工程。主线资源仍应放在 LGE/T2/C0 的 lesion proposal 系统上。[26]

最后给出面向决策的明确答案。第一，**SRR 应该继续，但必须降位为 stage-one evidence engine，而不是当前 cross-modal interaction dictionary 的终点形态**。第二，下一阶段最有希望的大改法，是 **shared evidence trunk 加 pathology-specific proposal dictionaries 加 soft-cascade refinement**；这是唯一同时正面回答你提出的 lesion proposal、prototype discrimination、cascade refinement 与 pathology-specific dense prediction 的方案。第三，**应该停止继续投入的方向**，包括继续做 dictionary topology 小变体、继续在当前 full-image dense head 上堆 compactness/containment、继续试弱 retrieval gate 或 late fusion 的细部差异、以及把 no-T2 myocardium 当 edema negative 的任何变体。第四，**外部资源只建议作为代码借鉴，不建议作为必须依赖的权重来源**，直到 2026 规则确认。第五，**下一轮 12-24 小时 Codex goal 应该写成系统任务，而不是小实验**：先实现病种 proposal dictionaries 与安全负样本采样器；再实现 soft ROI refinement 和 scar/edema 双 refinement heads；然后跑一个单折三阶段 schedule，至少包含“shared evidence dictionary 与双 D_{scar}/D_{edema} ”、“仅 scar 专属 proposal 加 shared edema proposal”、“无 prototype 的 conservative cascade”这三个 variants。每个 variant 都必须记录 proposal recall、心肌外 FP 比例、median component count、scar Dice、edema Dice、HD95，只有当 proposal 指标和 component 指标同时改善，才值得进入 fold expansion。[27]

如果只能押一个主方案，我押 **SRR-ProposeRefine**；如果需要一个稳健备胎，我选 **anatomy-first region-based cascade**；如果要列一个不推荐继续投入的清单，那就是 **dictionary-only 迭代、当前 head 上的 compactness-only 修补、以及任何把 missing T2 当 edema negative 的路线**。以“超过 nnU-Net baseline”为标准来筛选，只有 proposal、negative-space discrimination 与 refinement 被同时建起来，SRR 这条线才有现实可能进入真正的强系统区间。

Citation Repair Note

本文由 deep-research-report (2).md 渲染；原 Markdown 中的 ChatGPT 私有 citation 标记已按出现顺序转为正文编号 [n]，以避免 PDF 中出现不可读的 turn... 或私有 glyph。下方参考来源从同目录原始 PDF CARE 2026 Myocardium 定向深度研究报告.pdf 的文本层抽取，并去除了 utm_source=chatgpt.com 跟踪参数。

参考来源（从原 PDF 抽取）

1 5 20 GitHub - HiLab-git/MyoPS2020 · GitHub

<https://github.com/HiLab-git/MyoPS2020>

2 [1607.05194] HeMIS: Hetero-Modal Image Segmentation
<https://arxiv.org/abs/1607.05194>

3 10 13 14 MyoPS-Net: Myocardial Pathology Segmentation with Flexible Combination of Multi-Sequence CMR Images
<https://arxiv.org/abs/2211.03062>

4 18 Effect of Prior-based Losses on Segmentation Performance: A Benchmark
<https://arxiv.org/abs/2201.02428>

6 Anatomy-guided Pathology Segmentation
<https://papers.miccai.org/miccai-2024/079-Paper1464.html>

7 12 Similarity Memory Prior is All You Need for Medical Image ...
https://openaccess.thecvf.com/content/ICCV2025/papers/Tang_Similarity_Memory_Prior_is_All_You_Need_for_Medical_Image_ICCV_2025_paper.pdf

8 16 ULDor: A Universal Lesion Detector for CT Scans with Pseudo Masks and Hard Negative Example Mining
<https://arxiv.org/abs/1901.06359>

9 Prior Attention Network for Multi-Lesion Segmentation in Medical Images
<https://arxiv.org/abs/2110.04735>

11 22 MyoPS++ | CARE - Fudan ZMIC Lab
https://www.zmic.org.cn/care_2024/track4/

15 17 Iteratively Mining Unlabeled Lesions and Hard-Negative ...
<https://pubmed.ncbi.nlm.nih.gov/32894709/>

6

19 GitHub - Jun-Jie-Shi/PASSION: [ACM-MM'24 Oral] PASSION: Towards Effective Incomplete Multi-Modal Medical Image Segmentation with Imbalanced Missing Rates · GitHub
<https://github.com/Jun-Jie-Shi/PASSION>

21 GitHub - QJYBall/MyoPS-Net: MyoPS-Net: Myocardial Pathology Segmentation with Flexible Combination of Multi-Sequence CMR images · GitHub
<https://github.com/QJYBall/MyoPS-Net>

23 GenSegNet: Leveraging Synthetic Sequences and Pseudo Labels for Multi-sequence Myocardial Pathology Segmentation | Springer Nature Link
https://link.springer.com/chapter/10.1007/978-3-031-87009-5_22

24 CineMyoPS: Segmenting Myocardial Pathologies from Cine Cardiac MR
<https://arxiv.org/abs/2507.02289>

25 CineMA: A Foundation Model for Cine Cardiac MRI
<https://arxiv.org/html/2506.00679v1>

26 Multi-Source and Multi-Sequence Myocardial Pathology Segmentation Using a Cascading Refinement CNN
<https://arxiv.org/html/2409.12792v1>