

深度调研报告：2024年以来心肌CARE任务相关进展

自2024年以来，多项工作针对心肌病理分割与cine序列病灶推断提出了新方法。以下按**心肌病理分割（scar/edema/LGE）**、**cine MRI 病变推断**、**通用心脏分割架构创新**三类展开综述。

近年来针对scar增强与分割的研究有代表性的一项是Hasny et al. (2024, MICCAI)，其提出了一种**局部条件扩散模型**专门增强LGE图像中的梗死（scar）对比¹。该方法仅对心脏ROI部分进行噪声扩散，将合成的带增强对比的LGE图像作为训练目标，并训练一个分割网络。实验表明，增强后的图像能显著提高scar与正常心肌的对比¹。该项目开源了代码²，可以将其作为前处理模型，用于提高Lb1/Lb2中的scar/edema对比。集成难度较高（需搭建扩散模型管道），预期增益中等（主要对图像质量提升）。

Fang et al. (2026, MIA)提出了**强度先验提示引导的多序列心肌病变分割方法**^{3 4}。他们利用GPT-4o生成心肌、梗死和水肿的强度先验，并通过CLIP模型将这些文本化的强度信息编码为提示（prompt）融入多模态网络。该方法在新发布的MyoPS380数据集上实现了SOTA性能³。其代码已公开（GitHub链接嵌于文中）⁴。这一方法直接面向Lb1/Lb2（多序列scar/edema分割）任务，可作为改进多模态分割的方案。集成难度高（需要CLIP/GPT等组件），但论文结果优越，预期增益大。

针对多序列输入和缺模态问题，Thaler et al. (2024, arXiv/MyoPS++)提出了**多源多序列级联卷积网络MS-CaRe-CNN**⁵。该模型使用双阶段三维网络：先粗分LV/RV/Myo，再细化分割scar/edema。该方案在多序列（包括cine、LGE、T2）上协同训练，增强了对缺失序列的鲁棒性⁵。论文附在CARE2024 MyoPS竞赛，代码未开源，但该思路明确了层级分割对scar/edema定位的作用。与Lb1/Lb2高度相关：此为专门的多序列心肌病变分割网络，实现上难度中等偏高，无公开权重，收益待验证。

在单模态cine序列无对比下推断scar方面，Wang等(2025)提出了**动量-纹理融合网络MTI-MyoScarSeg**（arXiv）^{6 7}。该工作利用光流或DVF提取心肌运动信息（motion），同时利用纹理特征进行多分支融合，训练网络直接从cine帧中分割梗死区域^{6 7}。研究结果表明，在无LGE情况下，其scar分割效果可接近对比增强后的结果。尚未见开源代码。此方法与Lb3（单序列cine scar分割）高度相关，可考虑整合其运动分支，提高cine模型对scar的敏感度。集成难度高（需要额外运动估计模块），但预期对Lb3增益显著。

Chen et al. (2025, JCMR)开发了**cineCMR-SAM**方法，将SAM模型扩展到cine序列⁸。他们用时空自注意力（tSAM）对SAM进行微调，使其在cine序列上进行LV/RV/myo等结构分割，附带文本或框提示。该方法在cine多帧分割上取得了高准确度⁸。代码已开源（GitHub⁸），可用于cine分割任务。虽然初衷非scar分割，但其temporal SAM架构有望在Lv3上作为基础骨干，用于提升对心肌分割质量，间接帮助定位scar/edema。集成难度中等，需要训练Prompt，但代码齐全；对Lb3可带来LV/Myo分割提升，间接利于scar检测。

值得注意的一项工作来自Xu等(2026, medRxiv)的**CorSeg-CineSAX**^{9 10}。该团队构建了迄今最大规模的短轴cine标注集（1555例、12中心），训练了一个全新的MedNeXt-L模型并加上后处理约束，实现了零-shot泛化到多种心脏疾病的LV/RV/Myocardium分割^{9 10}。他们公开了源代码和预训练权重（GitHub）¹⁰。这一模型虽主要针对全心分割，也对Lb3有帮助：可直接用作cine心肌分割预模型，提供鲁棒的底层分割，且后处理中消除了连通性错误。集成难度低（直接加载权重），预期能显著提升Lb3中心肌分割精度，从而间接改善scar预测。许可证为CC BY 4.0，可在挑战赛中使用。

此外，Nicolas Noya开源了一个基于DenseNet的**心脏分割模型**^{11 12}（HuggingFace模型），该模型针对cine短轴图像分割LV/RV/Myocardium，拥有MIT许可证，可直接下载权重¹²。输入为单通道128×128像素切片，输出四通道概率图¹¹。尽管此模型规模较小，只能分割基础结构，但可作为一个快速基线，便于在Lb1/Lb2/Lb3任务中进行微调和病灶识别的特征预提取。集成简单，只需加载权重即可。

综上所述，1.1节重点的心肌病理分割工作包括：Hasny等（2024, MICCAI）提出的Scar增强扩散模型（公开代码）、Fang等（2026, MIA）的I-MMSeg强度先验分割（开源）、Thaler等（2024, CARE）多序列级联CNN（概念验证）、以及Xu等（2026, medRxiv）的CorSeg全心分割框架（开源预训练）。**相关性：**上述方法直接针对scar/edema分割，尤其Fang2026和Xu2026方案直接面向多序列和cine场景，对Lb1/Lb2/Lb3都有指导意义。**接入难度与收益：**CineMA、CorSeg这类已有开源权重方案接入难度低而回报高；I-MMSeg和Scar增强需要较大改动，但潜在提升显著；Thaler2024需重实现，风险与收益中等。

任务二：针对瓶颈的解决方案

B1 — 多序列缺模态策略

- Novosad et al. (2024, MICCAI)提出了**任务条件的专家模型混合（MoE）**，通过多个专家网络分别处理不同模态组合，并在线自蒸馏融合缺失通道¹³。该模型在脑部多模态（MS灶）分割上超过了普通模态丢弃训练策略¹³。开源情况未知，但其思路可借鉴到心脏场景：为Lb1/Lb2设计多个专家分支以适应缺失LGE或T2等。集成难度高（需要复杂网络设计），效果不明。
- Qu et al. (2024, BIBM)的**MMPL-Seg**提出了**提示学习处理缺模态**¹⁴。他们在U-Net中引入文本提示（prompt）来指导当某些模态缺失时的特征融合。此论文附有Github代码（WillowRW仓库），可直接下载【37+】（虽然README空）。方法在乳腺肿瘤分割任务上验证，开源权重不详。对于心脏多序列，如果把模态标签或强度信息作为“提示”，可能提高对缺失LGE情形的鲁棒性。难度中等，预期增益待评估。
- Zhu et al. (2025, MedIA)提出的**AdaMM**（Adaptive to Missing Modality via KD）针对脑肿瘤Brats数据，通过**知识蒸馏**和图模型学习缺失模态下的特征¹⁵。他们在缺某些MRI序列时，用完整模态网络指导缺模态网络，显著提升了分割性能¹⁵。开源GitHub¹⁵。思想可迁移到心脏：可设计类似KD过程，使只用C0或T2时依然逼近完整多序列模型输出。实现复杂度高，但代码开源帮助复现。

综上，B1主要趋势是通过**多专家网络、提示学习或知识蒸馏**增强模型对缺模态的容忍度。上述方法虽然多在脑部验证，但可为心脏多序列策略提供借鉴：**MoE模型和prompt提示机制**值得探索。实际可用性：AdaMM和MMPL-Seg的开源实现提供落地可能；MoE方法效果未知且实现更难。

B2 — Cine序列时序与运动建模

- Chen et al. (2025, JCMR)的cineCMR-SAM利用**时空SAM**实现多帧融合分割⁸。该方法通过时空自注意力处理cine帧，获得连贯的LV/myo分割⁸。尽管不专注scar，但其框架提供了一个现成的cine时序分割基线，可用作Lb3的基础。开源权重可在GitHub获取⁸。集成风险低（已有训练文件），可提升cine分割一致性。
- Bi et al. (2024, TMI)提出**SegMorph**，同时学习分割与3D心脏运动场¹⁶。他们采用RNN风格的VAE捕获一周期内运动，同时输出分割掩码。尽管主要验证了LV/RV分割，但“运动+分割”联合训练理念值得借鉴。未见公开权重。难度高（需实现复杂网络），但可提供cine序列内部一致性和形变信息，辅助Scar在时间上连贯检测。
- Wenbo等(2025, arXiv)的MTI-MyoScarSeg（见上文）结合了光流和图像特征⁶。它将运动信息直接用于分割，很适合Lb3。代码未公开。可以考虑将其光流提取器或运动流分支作为模块，增强我们当前CineMyoPS pipeline的时序感知。预期增益大，但集成难度高。

综述：B2方向集中于将**动态图像信息**引入分割网络，如时空注意力或运动估计模块。cineCMR-SAM提供了相对易用的基线（低风险高收益）。SegMorph和MTI代表更复杂的端到端运动建模路径，实施难度高但对Lb3潜在回报更大。建议优先尝试已开源的SAM-based方法，并考虑后续引入专门的运动分支。

B3 — 极不平衡小病灶分割

- de Lau et al. (2026, arXiv)提出**CATMIL** (Component-Adaptive Tversky + MIL) 损失¹⁷。该方法在MS病灶（小病灶）分割中加入了**连通组件加权Tversky**和**多实例学习（MIL）**项，使得每个病灶实例都能得到监督。结果显示，相比常规损失，CATMIL显著提高了小病灶召回率¹⁷。代码和预训练模型已开源¹⁸。该思路可直接应用到scar/edema（稀疏小区域）分割，增强模型对微小病灶的敏感性。集成难度中等（需定制损失函数），预期对精细HD提升有帮助。
- Visalakshi & Mohan (2025, Sci Reports)提出**SDHL+BCE**复合损失¹⁹。他们设计了一种可微分的Hausdorff损失（SDHL）来增强边界对齐，并与BCE结合使用。实验显示，在脑瘤分割中加入SDHL使肿瘤边界更锐利，提高了小肿瘤的分割质量¹⁹。该论文无开源代码，但方法可实现。对于CARE任务，可考虑在常规Dice/Cross-Entropy损失外增加类似SDHL或基于边界的惩罚，以改善scar/edema的边界检测。实现中等难度。

此外，还可考虑**Tversky loss**及其**Focal变体**（已被广泛用于不平衡分割）以及**扩散式标签权重**等常用方法。但最新工作如CATMIL和可微Hausdorff提供更专门的思路。综上，B3核心在于调整损失使小病灶贡献增大。可以选用开源实施的CATMIL代码¹⁷先行试验，效果可期。Hausdorff loss方法也值得探索，但实现稍复杂。

B4 — 跨中心域差异与小样本

Wong et al. (2025, arXiv)提出利用**扩散模型做领域适应**²⁰²¹。他们训练一个对源域图像生成器，用于合成与参考图像风格相似的目标域图像，从而提高分割模型在不同中心/协议数据上的泛化。这包括在训练和测试阶段都使用扩散模型进行混合适应，以**域随机化**方式扩充数据²⁰。实验显示，该方法显著提升了不同中心数据上的分割性能²⁰²¹。此方案为心脏MRI跨中心推广提供了启发，尤其在数据稀缺时利用生成数据。缺点是依赖复杂扩散训练，难度极高，且预训练模型不易获得。但思路可以参考，比如简单做**风格增强**或**傅里叶扰动**等强化方法，无需额外真实数据。

其他策略如对抗性训练、风格翻译（如CycleGAN）或**Fourier域随机化**等也可考虑。不过目前尚无已验证适合心脏MRI的案例。一个可落地的方案是**测试时自适应BN层**或**扩充源数据的风格变换**（如随机亮度/对比度），难度低但效果有限。总体而言，B4的方法多集中在数据增强和生成模型上。对于CARE来说，可保守尝试域随机化技术，同时依赖nnU-Net等鲁棒方法并通过TTA（测试时增强）等手段降低域偏差。

B5 — 心肌引导的细分割

B5强调“病灶需在心肌内”的先验。解决方式主要是**两阶段或层级分割**：先分割心肌，再在心肌内检测病变。一些工作提出了层级级联网络，但鲜有2024+专门报道。一个相关思路是在损失中加入**解剖约束**：例如CorSeg设计了分割后处理来保证心室-心肌拓扑合理¹⁰。对于CARE，可以借鉴：首先利用强心肌分割模型（如CorSeg、CineMA）获得准确心肌掩码，再在其基础上裁剪并分割scar/edema。训练时也可用**心肌注意力层**仅关注心肌内区域。尚无具体开源实现，只能基于现有分割结果编写后处理，实施难度中等但必要性高。预计两阶段思路（先心肌、后病灶）会显著改善HD指标。

B6 — 边界感知与HD优化

当前SOTA通常使用Dice或交叉熵损失，对HD较敏感。近年有方法设计**可微分的Hausdorff损失**（如上文Visalakshi 2025）¹⁹或**边界损失**（bLoss）¹⁹直接优化边界对齐。另可采用**形态学后处理**（如CorSeg的连通组件约束¹⁰）来消除孤立预测。没有2024以后的新开源损失类，但可以尝试已有实现：如nnU-Net中提供的HD95 loss模块，或利用椭圆性后的后处理（填洞、去小连通域）。这些通常实现难度低到中等。预计对HD、精细定位提升显著，尤其在scar/edema边界不清的情况下。

任务三：可用预训练模型盘点

3.1 心脏专用预训练模型

- **CineMA** (Zhang et al. 2025, arXiv ²²): 这是一个基于Masked Autoencoder的**Cine CMR基金模型**，在UK Biobank的大规模cine数据上自监督预训练，后在ACDC/M&Ms等数据上多任务微调 ²²。HuggingFace提供MIT许可的模型权重和对应代码 ²² ²³。相关任务包括短轴心脏分割（LV/RV/Myocardium），输入为单帧cine。对于Lb3来说，可以直接下载CineMA预训练权重进行fine-tune，用于cine心室/心肌分割再辅助scar检测。接入难度低，只需读取safetensors权重并适配网络。预期提升大，因为它是针对cine设计的大模型，捕获了丰富心脏解剖特征。许可证MIT，符合挑战赛要求，直接微调合规。
- **CorSeg-CineSAX** (Xu et al. 2026, preprint) ¹⁰: 一个MedNeXt-L模型在1,555例多中心cine短轴上训练，输出LV、RV、心肌分割 ⁹ ¹⁰。他们公开了全部代码和权重 ¹⁰。虽然输入为2D单帧，效果极好（跨域Gap仅0.002）。类标签映射为LV Cav, LV Myo, RV。我们可以将其作为cine序列（Lb3）上分割的起点，并借助其后处理框架保障连贯性。接入难度低（PyTorch模型即用），预期收益高（得到一个已训练成熟的cine分割模型）。许可证CC BY 4.0，可商用。
- **Heart_Segmentation (DenseNet)** (Noya) ¹¹ ¹²: HuggingFace上的一个MIT许可模型，实现了2D cine切片上LV/RV/Myocardium分割 ¹¹。包括完整权重（.pth文件）与实现 ¹²。训练数据来源未知（可能使用公开数据集），但直接支持短轴任务。类别映射与ACDC标准一致（背景+LV/RV/Myo）。接入简单，只需下载并替换最后层节点数（若需要）即可。预期增益有限（模型较小），可做快速baseline和辅助特征提取。

上述模型均在心脏MRI上训练，特别是cine序列，对Lb3最直接有用。它们可直接在CARE数据上fine-tune，无需额外训练数据，符合比赛规则。接入难度：CineMA与Heart_Segmentation风险低（开源简单），CorSeg稍高因后处理模块，但同样开源。

3.4 心脏配准/运动预训练模型

- **VoxelMorph** (Balakrishnan et al.) ²⁴: 通用的学习型配准库（Apache-2.0），提供多种预训练模型（脑部MRI等），可用于3D/4D影像配准 ²⁴。虽无专门的肝脏权重，但可利用其架构快速微调。接入难度低（pip安装），可在cine中进行帧间配准模块试验，潜在增强Lb3中的时序一致性。许可友好。
- **SynthMorph注册管道** (IvaMol) ²⁵: 提供使用SynthMorph方法训练对比不变配准模型的框架 ²⁵。支持多模态注册，与VoxelMorph集成。虽然没有预训练权重，但代码公开，可用来训练自己的cine配准模型。若有时间，可尝试利用该管道学习cine帧配准，辅助病灶时间一致性。实现复杂，但为后续拓展提供了契机。

3.6 自监督预训练资产

- **DeMooij et al. (2024)** ²⁶: 在cinesegmentation上评估了SimCLR、DINO、MIM等自监督方法。他们公开了用于CMR cine分割的**预训练代码仓库** ²⁶。结果表明，当标注样本极少时（10例），MIM预训练有助（Dice 0.86 vs 0.82），但样本量大时收益有限 ²⁶。对于CARE数据（64–220例），可以尝试用MAE或SimMIM在CARE图像上做自监督预训练，然后finetune常规模型。但根据作者结论，若有足够标注，可省略此步以节约时间。实现中等难度（已有代码可用），收益不确定。

其他通用自监督框架（如SwAV、MAE）也可直接应用，关键是CARE数据量不大，真正提升需评估。该领域最新结论倾向于**小样本场景下SSP有用，大量标注时影响不大** ²⁶。

For CARE团队 — 三项优先推荐

综合以上调研，我们建议团队首先考虑以下三件事：

- 1. 微调CineMA基础模型（投入：3-5人天，风险：低）。**CineMA是一款专为cine CMR设计的预训练模型²²。直接下载其预训练权重，针对CARE的cine数据（Lb3）进行微调。由于其基础模型已捕获了丰富的心室/心肌特征，对Scar分割提供了良好基础，预期能显著提升cine scar分割性能。
- 2. 实施I-MMSeg方法（投入：7-10人天，风险：高）。**Fang等的I-MMSeg方法利用LLM生成的心肌强度先验引导多序列病变分割³⁴。其代码已公开⁴，可在CARE多序列数据上进行实验。尽管集成LLM组件需要工作量大，但如果成功，可显著提升Lb1/Lb2的scar/edema分割精度。
- 3. 加入cine时序运动模块（投入：5-7人天，风险：中）。**采用已有运动分割融合思想（如MTI-MyoScarSeg⁶或SegMorph¹⁶）增强Lb3模型对时序的感知。可先尝试较容易的步骤：从已有代码库（如光流算法或SegMorph代码）复用运动提取模块，结合现有架构。预计对cine scar检出及帧间一致性有明显帮助。

这三项分别对应Lb3最大增益（CineMA和运动模块）和Lb1/Lb2（I-MMSeg）。投入和风险应权衡选择：CineMA微调门槛低且收益可靠，应最先尝试；I-MMSeg技术前沿但难度高，可并行预研；运动模块收益可观但实现复杂，可先在已有网络上做增量式改进。通过这些方案，我们可最大化利用现有开源资源，在比赛中获得竞争优势。

¹ ² Myocardial Scar Enhancement in LGE Cardiac MRI using Localized Diffusion | MICCAI 2024 - Open Access

<https://papers.miccai.org/miccai-2024/558-Paper3611.html>

³ ⁴ Incorporating modality-specific intensity prior as text prompt for multimodal myocardial pathology segmentation.

<https://www.lifescience.net/publications/1970197/incorporating-modality-specific-intensity-prior-as/>

⁵ Multi-Source and Multi-Sequence Myocardial Pathology Segmentation Using a Cascading Refinement CNN

<https://arxiv.org/html/2409.12792v1>

⁶ ⁷ Contrast-Free Myocardial Scar Segmentation in Cine MRI using Motion and Texture Fusion

<https://arxiv.org/html/2501.05241v1>

⁸ Cine cardiac magnetic resonance segmentation using temporal-spatial adaptation of prompt-enabled segment-anything-model: a feasibility study - ScienceDirect

<https://www.sciencedirect.com/science/article/pii/S1097664725000717>

⁹ ¹⁰ (PDF) CorSeg-CineSAX: An Open-Source Deep Learning Framework for Fully Automatic Segmentation of Short-Axis Cine Cardiac MRI Across Multiple Cardiac Diseases

https://www.researchgate.net/publication/403490811_CorSeg-CineSAX_An_Open-Source_Deep_Learning_Framework_for_Fully_Automatic_Segmentation_of_Short-Axis_Cine_Cardiac_MRI_Across_Multiple_Cardiac_Diseases

¹¹ ¹² NicolasNoya/Heart_Segmentation • Hugging Face

https://huggingface.co/NicolasNoya/Heart_Segmentation

¹³ A task-conditional mixture-of-experts model for missing modality segmentation | MICCAI 2024 - Open Access

<https://papers.miccai.org/miccai-2024/033-Paper2509.html>

- 14 dblp: Ruowen Qu
<https://dblp.org/pid/319/3271.html>
- 15 [2509.15017] No Modality Left Behind: Adapting to Missing Modalities via Knowledge Distillation for Brain Tumor Segmentation
<https://arxiv.org/abs/2509.15017>
- 16 SegMorph: Concurrent Motion Estimation and Segmentation for Cardiac MRI Sequences - Research Explorer The University of Manchester
<https://research.manchester.ac.uk/en/publications/segmorph-concurrent-motion-estimation-and-segmentation-for-cardia/>
- 17 18 Component-Adaptive and Lesion-Level Supervision for Improved Small Structure Segmentation in Brain MRI
<https://arxiv.org/html/2604.08015v1>
- 19 (PDF) A novel sub-differentiable hausdorff loss combined with BCE for MRI brain tumor segmentation using UNet variants
https://www.researchgate.net/publication/398956362_A_novel_sub-differentiable_hausdorff_loss_combined_with_BCE_for_MRI_brain_tumor_segmentation_using_UNet_variants
- 20 21 Can Diffusion Models Bridge the Domain Gap in Cardiac MR Imaging?
<https://arxiv.org/html/2508.06327v1>
- 22 23 mathpluscode/CineMA • Hugging Face
<https://huggingface.co/mathpluscode/CineMA>
- 24 GitHub - voxelmorph/voxelmorph: Unsupervised Learning for Image Registration • GitHub
<https://github.com/voxelmorph/voxelmorph>
- 25 GitHub - dulicui742/SynthMorph: Repository for training and using a contrast agnostic registration model based on the work done in SynthMorph. The contrast agnostic registration model may later be used in IvadoMed' s pipeline. • GitHub
<https://github.com/dulicui742/SynthMorph>
- 26 [2409.18100] Self-supervised Pretraining for Cardiovascular Magnetic Resonance Cine Segmentation
<https://arxiv.org/abs/2409.18100>